


# Sistemas de Recomendación



Georgina Flesia, Laura Alonso Alemany  
Diplomatura en Ciencia de Datos,  
Aprendizaje Automático y sus Aplicaciones  
FaMAF-UNC  
Agosto 2025



## Recommender Systems: An Introduction

by [Dietmar Jannach](#), [Markus Zanker](#), [Alexander Felfernig](#), [Gerhard Friedrich](#)

### AVERAGE CUSTOMER RATING:

☆☆☆☆☆ ( [Be the first to review](#) )



Registrieren, um sehen zu können, was deinen Freunden gefällt.

### FORMAT:

Hardcover

NOOKbook (eBook) - not available

[Tell the publisher you want this in NOOKbook format](#)

### NEW FROM BN.COM

~~\$65.00~~ List Price

**\$52.00** Online Price  
(You Save 20%)

**Add to Cart**

### NEW & USED FROM OUR

New starting at **\$56.46** (You Save 13%)

Used starting at **\$51.98** (You Save 21%)

**See All Prices**

[Table of Contents](#)

### Customers who bought this also bought



Basado en el tutorial de Dietmar Jannach, Markus Zanker and Gerhard Friedrich en IJCAI 2013

[http://ijcai13.org/files/tutorial\\_slides/td3.pdf](http://ijcai13.org/files/tutorial_slides/td3.pdf)


El excelente notebook de James Le

<https://github.com/khanhnamle1994/movielens/blob/master/README.md>

También para ver, el artículo de la Wikipedia sobre sistemas de recomendación

[http://en.wikipedia.org/wiki/Recommender\\_system](http://en.wikipedia.org/wiki/Recommender_system)

# La solución



# La solución

Dado un usuario, recomendarle productos que pueden interesarle

- Recomendar tratamientos de salud preventivos
- Personalizar cursos
- Recomendar películas, libros en la biblioteca, restaurantes, amigos, amores

# Qué tenemos

- Muchos datos de comportamientos de las personas
- “Etiquetas” asociadas a esos comportamientos:
  - Likes
  - Buenos resultados al final de una secuencia (reinforcement learning!)
- Contenido (palabras, etiquetas)

# Qué no tenemos

- Una buena abstracción sobre los datos
- Datos suficientes para items nuevos, raros, usuarios nuevos, perfiles únicos

# Qué no tenemos

- Una buena abstracción sobre los datos
- Datos suficientes para items nuevos, raros, usuarios nuevos, perfiles únicos

# Cómo lo solucionamos?



# Qué no tenemos

- Una buena abstracción sobre los datos
- Datos suficientes para items nuevos, raros, usuarios nuevos, perfiles únicos

# Cómo lo solucionamos?

Embeddings!

# Qué no tenemos

- Una buena abstracción sobre los datos
- Datos suficientes para items nuevos, raros, usuarios nuevos, perfiles únicos

# Cómo lo solucionamos?

Embeddings!

En este área se llama... matrix factorization

# Qué no tenemos


- Una buena abstracción sobre los datos
- Datos suficientes para items nuevos, raros, usuarios nuevos, perfiles únicos

# Cómo lo solucionamos?

Embeddings!


En este área se llama... matrix factorization

Problema del túnel: hay que explorar o buscar serendipia: recomendar items fuera del espacio de interés conocido




# Aproximaciones a recomendación


Reducir la información estimando relevancia




# Aproximaciones a recomendación



# Filtrado colaborativo (*collaborative filtering*)




# Basado en contenido






# Basado en conocimiento




# Híbrido



Híbrido: compuesto de varios mecanismos

# **Filtrado Colaborativo**

# Filtrado colaborativo (*collaborative filtering*)



# Filtrado colaborativo

- La aproximación más usada para generar recomendaciones
  - Bien conocida, con muchos algoritmos implementados y variantes
  - Aplicable a muchos dominios
- 
- Se usa la “sabiduría de las masas” (*"wisdom of the crowd"*)
  - Se asume que los usuarios con gustos parecidos en el pasado tendrán usos parecidos en el futuro

# Entrada - Salida

## Input

Una matriz de relaciones usuario - item (valoraciones, compras, usos...)

## Output

- Una predicción de cuánto le gustará un determinado item a un usuario
- Una lista de los items más recomendados

# Entrada - Salida: ejemplo

Le gustará el item 5 a Alice?

|       | Item1 | Item2 | Item3 | Item4 | Item5 |
|-------|-------|-------|-------|-------|-------|
| Alice | 5     | 3     | 4     | 4     | ?     |
| User1 | 3     | 1     | 2     | 3     | 3     |
| User2 | 4     | 3     | 4     | 3     | 5     |
| User3 | 3     | 3     | 1     | 5     | 4     |
| User4 | 1     | 5     | 5     | 2     | 1     |

# Recomendación por vecinos más cercanos

Dada una matriz usuarios - items, un usuario  $U$  y un item  $I$  que  $U$  no ha visto todavía

1. Encontrar los  $k$  usuarios más semejantes a  $U$  (*k-nearest-neighbors*)
2. Encontrar el valor que esos  $k$  usuarios han asignado a  $I$
3. Darle a  $I$  un valor obtenido del valor asignado por los  $k$  usuarios

Parámetros:

- ¿Cómo determinar semejanza?
- ¿Qué número  $k$  de usuarios?
- ¿Cómo determinar el valor asignado a  $I$ ? ¿Promedio? ¿Promedio pesado por distancia? ¿Heurística?



# Semejanza es correlación

Correlación de Pearson para *collaborative filtering*

$a, b$ : usuarios

$r_{a,p}$ : valoración del usuario  $a$  para el item  $p$

$P$ : conjunto de items valorados por  $a$  y por  $b$

$$\text{sim}(a, b) = \frac{\sum_{p \in P} (r_{a,p} - \bar{r}_a)(r_{b,p} - \bar{r}_b)}{\sqrt{\sum_{p \in P} (r_{a,p} - \bar{r}_a)^2} \sqrt{\sum_{p \in P} (r_{b,p} - \bar{r}_b)^2}}$$

# Semejanza es correlación

|       | Item1 | Item2 | Item3 | Item4 | Item5 |
|-------|-------|-------|-------|-------|-------|
| Alice | 5     | 3     | 4     | 4     | ?     |
| User1 | 3     | 1     | 2     | 3     | 3     |
| User2 | 4     | 3     | 4     | 3     | 5     |
| User3 | 3     | 3     | 1     | 5     | 4     |
| User4 | 1     | 5     | 5     | 2     | 1     |



sim = 0,85


sim = 0,00

sim = 0,70

sim = -0,79

# Semejanza es correlación

- Funciona mejor que el coseno
- Registra las diferencias en comportamiento de valoración



# Recomendar a partir de la semejanza

- Una función de predicción común:

$$\mathit{pred}(a, p) = \overline{r}_a + \frac{\sum_{b \in N} \mathit{sim}(a, b) * (r_{b,p} - \overline{r}_b)}{\sum_{b \in N} \mathit{sim}(a, b)}$$

1. Calcula si la valoración de los vecinos para el item  $i$  son más altas o más bajas que su promedio
2. Combina las diferencias de valoración con el promedio, pesándolas por su semejanza  $\alpha$
3. Sumar o restar el sesgo del vecino del promedio del usuario objetivo, y usar eso como una predicción

# Mejorar la recomendación

- No todas las valoraciones valen lo mismo: estar de acuerdo en items controvertidos es más informativo que estar de acuerdo en items con acuerdo general

Solución: dar más peso a items con mayor varianza en sus valoraciones

- Valorar el número de items co-valorados, usando "*significance weighting*", por ejemplo, reduciendo el peso cuando el número de items co-valorados es bajo
- Aumentar el peso de los vecinos más cercanos (*case amplification*)
- Seleccionar vecinos no por número sino por umbral de semejanza

# Memoria vs. Modelo

Collaborative filtering basado en usuarios es "*memory-based*"

- Se usa la matriz de valoraciones directamente
  - Entrenamiento poco costoso
  - Predicción muy costosa
- No escala para la mayor parte de escenarios del mundo real

Aproximaciones basadas en modelos

- Se aprende un modelo off-line, se reentrena periódicamente
- En tiempo de predicción se usa el modelo
- Cómo podría entrar clustering aquí?

# Modelo basado en items

Una aproximación basada en modelos, con la idea básica de usar la semejanza entre items (y no entre usuarios)

1. Buscar items semejantes a Item5
2. Extrapolar la valoración de Alice para esos items para predecir la valoración para Item5

|       | Item1 | Item2 | Item3 | Item4 | Item5 |
|-------|-------|-------|-------|-------|-------|
| Alice | 5     | 3     | 4     | 4     | ?     |
| User1 | 3     | 1     | 2     | 3     | 3     |
| User2 | 4     | 3     | 4     | 3     | 5     |
| User3 | 3     | 3     | 1     | 5     | 4     |
| User4 | 1     | 5     | 5     | 2     | 1     |

# Semejanza para items: coseno

- Mejores resultados para filtrado item-a-item

$$\text{sim}(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{|\vec{a}| * |\vec{b}|}$$

- El coseno normalizado (*adjusted cosine similarity*)
  - Usa el promedio de valoraciones del usuario y transforma con eso las valoraciones originales
  - U: conjunto de usuarios que han valorado los items  $a$  y  $b$

$$\text{sim}(\vec{a}, \vec{b}) = \frac{\sum_{u \in U} (r_{u,a} - \bar{r}_u)(r_{u,b} - \bar{r}_u)}{\sqrt{\sum_{u \in U} (r_{u,a} - \bar{r}_u)^2} \sqrt{\sum_{u \in U} (r_{u,b} - \bar{r}_u)^2}}$$



# Recomendar de semejanza entre items

- Una función de predicción común:

$$pred(u, p) = \frac{\sum_{i \in ratedItem(u)} sim(i, p) * r_{u,i}}{\sum_{i \in ratedItem(u)} sim(i, p)}$$

# Cómo lo hacemos escalar


Basarse en items solamente no garantiza escalabilidad

- Pre-procesar todas las semejanzas entre items off-line
- Más estables que las semejanzas entre usuarios
- Más densas, aunque sigue habiendo muchos items sin co-valoraciones
- La vecindad activa en tiempo de predicción es bastante chica, porque sólo se usan items que el usuario haya valorado
- Se puede poner un umbral de número mínimo de co-valoraciones
- Usar clustering?

# Valoraciones

- Muchos usuarios no quieren dejar valoraciones: cómo estimularlos
- Obtener valoraciones implícitas
  - Compras
  - Clicks, vistas de página, tiempo de permanencia en la pantalla, descargas
  - Visitas al médico, siniestros, pulsaciones por minuto, interacciones en redes sociales...
- Pero ¿estamos interpretando correctamente el comportamiento del usuario?
  - Compra no es lo mismo que satisfacción
  - Podemos comprar para otra persona (un regalo, un encargo)

# Escasez de datos (data sparsity)



# Escasez de datos (data sparsity)

*Cold start*

¿Cómo recomendar items nuevos? ¿Cómo recomendar a usuarios nuevos?

- Forzar a los usuarios a valorar un conjunto de items (con aprendizaje activo!)
- Combinar con otro método en el principio: basado en contenido, demográfico, no personalizado
- Aumentar la potencia de vecinos más cercanos, porque el conjunto de vecinos más cercanos puede ser demasiado chico: asumir transitividad de vecindades

# Otros métodos basados en modelos

- Factorización de matrices (PCA)
  - Reglas de Asociación
  - Métodos probabilísticos (bayesianos)
  - Clustering
- 
- Se reduce el espacio
  - Se hace más denso → menos escasez de datos (*cold start, long tail*)
  - Emergen las causas latentes
  - Se pierde información → podemos sacrificar más información cuanto más redundante sea la información, depende del dominio

# Factorización de matrices


SVD:  $M_k = U_k \times \Sigma_k \times V_k^T$

| U <sub>k</sub> | Dim1  | Dim2  |
|----------------|-------|-------|
| Alice          | 0.47  | -0.30 |
| Bob            | -0.44 | 0.23  |
| Mary           | 0.70  | -0.06 |
| Sue            | 0.31  | 0.93  |

| V <sub>k</sub> <sup>T</sup> | Terminator | Die Hard | Twins | Eat Pray Love | Pretty Woman |
|-----------------------------|------------|----------|-------|---------------|--------------|
| Dim1                        | -0.44      | -0.57    | 0.06  | 0.38          | 0.57         |
| Dim2                        | 0.58       | -0.66    | 0.26  | 0.18          | -0.36        |

| Σ <sub>k</sub> | Dim1 | Dim2 |
|----------------|------|------|
| Dim1           | 5.63 | 0    |
| Dim2           | 0    | 3.23 |

Predicción:  $\hat{r}_{ui} = \bar{r}_u + U_k(Alice) \times \Sigma_k \times V_k^T(EPL)$   
 $= 3 + 0.84 = 3.84$





# Reglas de asociación

1. Transformar valoraciones a binario (1 = por encima del promedio)
- |        | Item 1 | Item 2 | Item 3 | Item 4 | Item 5 |
|--------|--------|--------|--------|--------|--------|
| Alice  | 1      | 0      | 0      | 0      | ?      |
| User 1 | 1      | 0      | 1      | 0      | 1      |
| User 2 | 1      | 0      | 1      | 0      | 1      |
| User 3 | 0      | 0      | 0      | 1      | 1      |
| User 4 | 0      | 1      | 1      | 0      | 0      |
2. Minar reglas de
3. Reglas relevantes antecedente pero no el  
consecuente
4. Ordenar por co

# Métodos probabilísticos

A partir de la matriz de valoraciones, determinar la probabilidad de que un usuario valore positivamente un ítem, usando el Teorema de Bayes

$$P(Y|X) = \frac{P(X|Y) \times P(Y)}{P(X)} \qquad P(Y|X) = \frac{\prod_{i=1}^d P(X_i|Y) \times P(Y)}{P(X)}$$

Naïve Bayes: asumimos que las valoraciones son independientes!

# Métodos probabilísticos

|       | Item1 | Item2 | Item3 | Item4 | Item5 |
|-------|-------|-------|-------|-------|-------|
| Alice | 1     | 3     | 3     | 2     | ?     |
| User1 | 2     | 4     | 2     | 2     | 4     |
| User2 | 1     | 3     | 3     | 5     | 1     |
| User3 | 4     | 5     | 2     | 3     | 3     |
| User4 | 1     | 1     | 5     | 2     | 1     |

$X = (\text{Item1} = 1, \text{Item2} = 3, \text{Item3} = \dots)$

$$P(X|\text{Item5} = 1)$$

$$\begin{aligned}
 &= P(\text{Item1} = 1|\text{Item5} = 1) \times P(\text{Item2} = 3|\text{Item5} = 1) \\
 &\times P(\text{Item3} = 3|\text{Item5} = 1) \times P(\text{Item4} = 2|\text{Item5} = 1) \\
 &= \frac{2}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \approx 0.125
 \end{aligned}$$

$$P(X|\text{Item5} = 2)$$

$$\begin{aligned}
 &= P(\text{Item1} = 1|\text{Item5} = 2) \times P(\text{Item2} = 3|\text{Item5} = 2) \\
 &\times P(\text{Item3} = 3|\text{Item5} = 2) \times P(\text{Item4} = 2|\text{Item5} = 2) \\
 &= \frac{0}{0} \times \dots \times \dots \times \dots = 0
 \end{aligned}$$

# Slope One

Diferencial de popularidad entre items

|       | Item1 | Item5 |
|-------|-------|-------|
| Alice | 2     | ?     |
| User1 | 1     | 2     |

-

$$p(\text{Alice}, \text{Item5}) = 2 + (2-1) = 3$$

Obtener el promedio de estas diferencias en co-valoraciones para hacer la predicción

# Evaluación

Error cuadrado (RMSE)

# Fortalezas y limitaciones de collaborative filtering


- No supervisado, poco costoso: no requiere introducir información manualmente
- Bien conocido, con buenos resultados en muchos dominios

pero...

- Requiere valoraciones de los usuarios
- Sufre en los puntos de escasez de datos → aplicar generalización
- No integrado con otras fuentes de conocimiento, sin explicación de resultados
- Es un fenómeno complejo que estamos reduciendo, hay que ver cómo incorporar otros factores como tiempo, costo, sorpresa, etc.

**Basado en Contenido**

# Basado en contenido





# Fortalezas de basado en contenido

Items con pocas valoraciones, usuarios con pocas valoraciones

Se buscan items / usuarios semejantes basándose en características, no en comportamiento (contenido, género, características demográficas)

- Necesitamos información sobre los items
  - Categoría
  - Contenido
- Proyectar el perfil del usuario en esa nueva información

# Contenido de los items

Los documentos textuales son una buena metáfora



| Title                | Genre             | Author            | Type      | Price | Keywords                                                         |
|----------------------|-------------------|-------------------|-----------|-------|------------------------------------------------------------------|
| The Night of the Gun | Memoir            | David Carr        | Paperback | 29.90 | Press and journalism, drug addiction, personal memoirs, New York |
| The Lace Reader      | Fiction, Mystery  | Brunonia Barry    | Hardcover | 49.90 | American contemporary fiction, detective, historical             |
| Into the Fire        | Romance, Suspense | Suzanne Brockmann | Hardcover | 45.90 | American fiction, murder, neo-Nazism                             |

# Representación de contenido, semejanza

## Representación de los items

| Title                | Genre             | Author            | Type      | Price | Keywords                                                         |
|----------------------|-------------------|-------------------|-----------|-------|------------------------------------------------------------------|
| The Night of the Gun | Memoir            | David Carr        | Paperback | 29.90 | Press and journalism, drug addiction, personal memoirs, New York |
| The Lace Reader      | Fiction, Mystery  | Brunonia Barry    | Hardcover | 49.90 | American contemporary fiction, detective, historical             |
| Into the Fire        | Romance, Suspense | Suzanne Brockmann | Hardcover | 45.90 | American fiction, murder, neo-Nazism                             |

## Perfil del usuario

| Title | Genre   | Author                       | Type      | Price | Keywords                    |
|-------|---------|------------------------------|-----------|-------|-----------------------------|
| ...   | Fiction | Brunonia, Barry, Ken Follett | Paperback | 25.65 | Detective, murder, New York |

# Representación de contenido, semejanza

## Representación de los items

| Title                | Genre             | Author         | Type      | Price | Keywords                                                         |
|----------------------|-------------------|----------------|-----------|-------|------------------------------------------------------------------|
| The Night of the Gun | Memoir            | David Carr     | Paperback | 29.90 | Press and journalism, drug addiction, personal memoirs, New York |
| The Lace Reader      | Fiction, Mystery  | Brunonia Barry | Hardcover | 49.90 | American contemporary fiction, detective,                        |
| Into the Fire        | Romance, Suspense |                |           |       | n, murder,                                                       |

Semejanza item - usuario:  
Solapamiento de palabras clave  
(Dice coefficient, coseno)

$$\frac{2 \times |keywords(b_i) \cap keywords(b_j)|}{|keywords(b_i)| + |keywords(b_j)|}$$

## Perfil del usuario

| Title | Genre   | Author                       | Type      | Price | Keywords                    |
|-------|---------|------------------------------|-----------|-------|-----------------------------|
| ...   | Fiction | Brunonia, Barry, Ken Follett | Paperback | 25.65 | Detective, murder, New York |

# Recomendar items por semejanza entre items

Para un item  $i$  no valorado por el usuario  $U$

1. Encontrar items semejantes a  $i$  (por contenido, por categoría) ya valorados por el usuario
2. Usar las valoraciones de esos items para valorar  $i$

# Recomendación explicativa

Tomar los items valorados como ejemplos etiquetados y aplicarles un algoritmo de aprendizaje automático interpretable (árbol de decisión, reglas de decisión (RIPPER))

- Funciona bien para pocas características, bien generales
- Las reglas que se infieren se pueden integrar con conocimiento del dominio

# Fortalezas y limitaciones de basado en contenido

- Útil para escasez de datos de comportamiento
- No se requiere comunidad, sino solamente al propio usuario → privacidad
- Necesita algunos datos de partida (no sirve en *cold start* absoluto)
- Sobreajuste
- Las características pueden no representar bien el problema

# Sistemas Híbridos



# Combinar estrategias

- Atacar el *cold start* usando elicitación de restricciones → basado en active learning?
- Usar recomendación basada en contenido cuando tenemos poca información de comportamiento (item nuevo, usuario nuevo), o cuando no se quiere compartir la información de comportamiento
  - ¿en qué momento cambiar de estrategia?
- Usar PCA para atacar la escasez de datos y evitar overfitting
- Usar clustering para escalabilidad y alcanzar serendipia

# **Veamos algunos ejemplos**

<https://github.com/nakulcr7/recommender-system-instacart>